



中山大學  
SUN YAT-SEN UNIVERSITY

# 数据安全和隐私保护

## 实验一实验基础工具使用

姓名 黄志鹏

学号 待填写

学院 网络空间安全学院

专业 网络空间安全

2026 年 9 月 13 日

## 目录

|          |                             |          |
|----------|-----------------------------|----------|
| <b>1</b> | <b>实验要求</b>                 | <b>1</b> |
| <b>2</b> | <b>实验原理</b>                 | <b>1</b> |
| 2.1      | Git 版本控制原理 . . . . .        | 1        |
| 2.2      | Codex 辅助编程原理 . . . . .      | 1        |
| 2.3      | LaTeX 图片排版原理 . . . . .      | 2        |
| <b>3</b> | <b>实验设置</b>                 | <b>2</b> |
| <b>4</b> | <b>实验过程</b>                 | <b>2</b> |
| 4.1      | LaTeX 图片排版 . . . . .        | 2        |
| 4.2      | Git 仓库与提交 . . . . .         | 3        |
| 4.3      | Codex 与 CC Switch . . . . . | 4        |
| 4.4      | 代码修改情况 . . . . .            | 4        |
| <b>5</b> | <b>实验结果与分析</b>              | <b>7</b> |
| <b>6</b> | <b>实验总结</b>                 | <b>8</b> |
| <b>A</b> | <b>最终 Git 历史</b>            | <b>8</b> |
| <b>B</b> | <b>最终工作区状态</b>              | <b>8</b> |

# 1 实验要求

本次实验围绕科研代码管理、AI 辅助编程和实验报告撰写三个基础环节展开。具体要求如下：

1. 掌握 LaTeX 中插入图片的基本方法，至少插入一张实验结果图，为图片设置规范的图题和标签，并在正文中使用交叉引用；
2. 掌握 Git 和 GitHub 的仓库创建、克隆、提交、上传和更新流程，提交前使用 `git status`、`git diff` 和 `git log` 核对变更；
3. 完成 Codex 的基本使用，了解 CC Switch 的供应商配置与切换方法，并使用 Codex 完成至少一次代码阅读、生成或修改任务；
4. 报告应记录关键命令、重要操作、运行结果、代码修改情况和实验总结，且不得泄露 API Key、密码或访问令牌。

本报告以一个仅依赖 Python 标准库的文本词频统计程序作为 Codex 辅助编程任务，并用程序输出制作 LaTeX 矢量图。GitHub 远程地址使用个人账号时才可填写；本地已用 bare remote 完成等价的 push/pull 流程验证，报告中不伪造个人 GitHub 操作记录。

# 2 实验原理

## 2.1 Git 版本控制原理

Git 将一次修改依次保存在工作区、暂存区和本地仓库中。工作区用于编辑文件，`git add` 将明确选择的变化放入暂存区，`git commit` 把暂存内容记录为一个带有说明的版本。`git status` 显示整体状态，`git diff` 检查未暂存修改，`git diff --staged` 检查即将提交的修改，`git log` 用于追踪历史。远程同步时，`git push` 将本地提交发送到远程仓库，`git pull` 获取远程提交并合并到本地。

## 2.2 Codex 辅助编程原理

AI 辅助编程的可靠流程不是直接接受生成结果，而是先让工具读取项目并说明入口，再提出小而明确的任务，审阅准备执行的命令和差异，运行程序与测试，最后使用 Git 独立检查。这样可以把“理解、修改、验证、保存”分成可核对的步骤，降低误改文件、引入依赖或泄露敏感信息的风险。

## 2.3 LaTeX 图片排版原理

LaTeX 通过 `graphicx` 宏包将图片排入文档，`caption` 产生图题，`label` 与 `ref` 建立交叉引用。对折线图、柱状图和结构图等结果，优先使用 PDF 或 SVG 等矢量格式，可以在改变版面尺寸时保持文字和曲线清晰。本实验使用 PDF 矢量柱状图记录词频结果。

## 3 实验设置

表 1: 实验环境

| 项目        | 设置                                     |
|-----------|----------------------------------------|
| 操作系统与终端   | Windows, PowerShell                    |
| Git       | git version 2.53.0.windows.3           |
| Python    | Python 3.12.14                         |
| LaTeX     | MiKTeX-XeTeX 4.15, MiKTeX 25.4         |
| Codex     | codex-cli 0.153.4; 使用 Codex 桌面会话辅助完成任务 |
| CC Switch | 检测到 Windows 客户端可执行文件；切换时不在代码或报告中保存密钥   |

程序入口为 `code/text_stats.py`，输入文件为 `code/sample.txt`。程序使用正则表达式提取英文单词、数字和中文字符；英文单词统一转换为小写，中文按单字统计，因此无需安装第三方分词包。实验命令为：

```
1 python code/text_stats.py code/sample.txt --top 8
2 python -m py_compile code/text_stats.py
```

Listing 1: 实验复现命令

本地 Git 提交使用仓库级示例身份实验报告作者 `<student@example.com>`，仅用于演示提交记录，不代表 GitHub 登录凭据。实验过程中没有在环境变量、配置文件、代码、报告或图片中写入 API Key。

## 4 实验过程

### 4.1 LaTeX 图片排版

首先将实验图片统一放入 `result` 目录，并使用短英文文件名。程序运行后得到 67 个 token 和 56 个不同 token，取出现次数最高的 8 项制作柱状图。图 1 使用 PDF 格

式，正文通过标签引用该图，放大后仍可保持柱线和文字的清晰度。




图 1: 文本词频统计结果

## 4.2 Git 仓库与提交

项目初始目录不是 Git 仓库，因此先在项目根目录执行初始化并设置仓库级提交身份：

```
1 git init -b main
2 git config user.name "实验报告作者"
3 git config user.email "student@example.com"
4 git add README.md .gitignore code/text_stats.py code/sample.txt result/README.
   md report/README.md
5 git diff --staged
6 git commit -m "add first experiment program"
```

Listing 2: 初始化仓库与第一次提交

第一次提交只包含 README、程序和输入样例。完成程序测试、结果图和报告后，先检查状态与差异，再完成第二次提交：

```
1 git status
2 git diff
3 git add main.tex result/text_stats_output.txt result/text_stats_bar.pdf
```

```

4 git diff --staged
5 git commit -m "add experiment result and report"

```

Listing 3: 检查修改并提交实验结果

为了验证远程同步语义，本地在仓库的 Git 元数据目录中建立了一个 bare remote，执行了与 GitHub 相同的命令：

```

1 git remote add origin .git/remote.git
2 git push -u origin main
3 # 在另一个克隆目录修改 README 并提交、推送
4 git pull --ff-only
5 git log --oneline --graph --decorate -n 5

```

Listing 4: 远程推送与更新同步

如果要连接个人 GitHub 仓库，只需将 origin 替换为个人 HTTPS 地址，再执行 `git push -u origin main`；首次认证应通过浏览器或凭据管理器完成，不能把密码或令牌写进命令、脚本或报告。本地最终提交历史记录见图 2 和附录输出文件。

### 4.3 Codex 与 CC Switch

本次任务中先让 Codex 阅读项目，确认项目只有 LaTeX 模板和实验说明，没有现成代码入口；随后提出“生成一个仅使用标准库、支持 UTF-8、可指定输出条数的文本词频统计程序，并给出测试命令”的小任务。生成后逐行检查了正则表达式、输入文件编码、排序规则和非法参数处理，再独立运行程序、语法检查和 `--top 0` 边界测试，最后用 Git 检查文件变化。

本机已检测到 Codex CLI 和 CC Switch Windows 客户端。CC Switch 的安全使用步骤是：打开 Codex 页面，添加供应商，按供应商文档填写名称、Endpoint URL 和模型，保存后启用供应商，重新打开 Codex，再用 `/status` 和一个小问题检查生效情况。API Key 只应保存在受保护的本地配置或系统凭据中，不应出现在报告、截图、Git 仓库或命令历史中。本报告只记录配置流程和字段名称，不记录任何认证值。

### 4.4 代码修改情况

新增的程序入口如下。程序对不存在的输入文件和非正整数 `--top` 参数主动报错，避免生成误导性的空结果。

```

1 #!/usr/bin/env python3
2 """Count word frequencies in a UTF-8 text file.
3
4 English words and numbers are grouped case-insensitively. Chinese text is
5 counted character by character so that the program works without external

```

## Terminal verification record

Reproducible outputs collected from the experiment workspace

### Program test

```
$ python code/text_stats.py code/sample.txt --top 8
tokens: 67    unique: 56
top: and 3 | a 2 | codex 2 | git 2
test 2 | the 2 | Chinese characters 2 each
```

### Validation

```
$ python -m py_compile code/text_stats.py
PASS: syntax check completed
$ python code/text_stats.py code/sample.txt --top 0
PASS: rejected with exit code 1
```

### Git history

```
$ git log --oneline --graph --decorate -n 5
* b79d30c (HEAD -> main, origin/main, origin/HEAD) package completed experiment report
* 293077d update README from remote
* 4c692ac add experiment result and report
* ab6c0d2 add first experiment program
```

### Remote sync

```
$ git push origin main
OK: local bare remote received main
$ git pull --ff-only
OK: fast-forward from 4c692ac to 293077d
```

### Workspace check

```
$ git status --short
(no output)
PASS: clean working tree after packaging the report
```

Vector PDF record; no credentials, tokens, or personal account secrets are included.

图 2: 关键命令执行记录

```
6 tokenization packages.
7 """
8
9 from __future__ import annotations
10
11 import argparse
12 import re
13 from collections import Counter
14 from pathlib import Path
15
16
17 TOKEN_RE = re.compile(r"[A-Za-z0-9_]+|[\u4e00-\u9fff]")
18
19
20 def tokens(text: str) -> list[str]:
21     """Return normalized English/numeric tokens and Chinese characters."""
22     return [token.lower() for token in TOKEN_RE.findall(text)]
23
24
25 def count_words(path: Path) -> Counter[str]:
26     """Read *path* as UTF-8 and count its tokens."""
27     return Counter(tokens(path.read_text(encoding="utf-8")))
28
29
30 def build_parser() -> argparse.ArgumentParser:
31     parser = argparse.ArgumentParser(description="Count text token frequencies"
32 )
33     parser.add_argument("input", type=Path, help="UTF-8 text file to analyze")
34     parser.add_argument("--top", type=int, default=10, help="number of rows to show")
35     return parser
36
37
38 def main() -> int:
39     args = build_parser().parse_args()
40     if args.top < 1:
41         raise SystemExit("--top must be a positive integer")
42     if not args.input.is_file():
43         raise SystemExit(f"input file not found: {args.input}")
```

```
44 counts = count_words(args.input)
45 print(f"file: {args.input}")
46 print(f"tokens: {sum(counts.values())}")
47 print(f"unique: {len(counts)}")
48 print("rank token count")
49 for rank, (token, count) in enumerate(
50     sorted(counts.items(), key=lambda item: (-item[1], item[0]))[: args.top
51 ],
52     start=1,
53 ):
54     print(f"{rank:>4} {token:<12} {count:>5}")
55 return 0
56
57 if __name__ == "__main__":
58     raise SystemExit(main())
```

Listing 5: 文本词频统计程序

## 5 实验结果与分析

正常运行输出如下，结果文件保存在 `result/text_stats_output.txt`:

```
1 file: code\sample.txt
2 tokens: 67
3 unique: 56
4 rank token count
5     1 and          3
6     2 a            2
7     3 codex        2
8     4 git          2
9     5 test         2
10    6 the          2
11    7 制           2
12    8 控           2
```

Listing 6: 程序运行输出

实验结果表明，样例共提取 67 个 token，其中不同 token 为 56 个；出现次数最多的是 `and`，共 3 次。`a`、`codex`、`git`、`test` 和 `the` 各出现 2 次。中英文混合输入能够被统一处理，英文大小写不会造成重复计数，中文字符则按字符进行可复现的简单统计。

边界测试中，执行 `python code/text_stats.py code/sample.txt --top 0` 得到错误信息 “-top must be a positive integer”，进程以非零状态退出，说明命令行参数校验生效。`python -m py_compile code/text_stats.py` 也顺利完成，说明程序不存在语法错误。

## 6 实验总结

通过本次实验，我把一个小程序从需求、实现、运行、结果保存到版本提交完整地走了一遍。Git 的价值不仅是备份，更重要的是在提交前通过 `status` 和 `diff` 明确“改了什么”，在提交后通过 `log` 追溯“什么时候改的”。因此一次提交应只包含一个清晰目标，暂存时也应明确列出文件。

使用 Codex 时，先限定任务范围再审阅修改内容十分重要。生成代码不能替代运行测试，能运行也不能替代检查依赖、输入边界和敏感信息。CC Switch 提供了供应商切换便利，但本地代理和多供应商配置会增加新的信任边界，密钥保护、端口暴露和配置恢复都需要单独检查。

最后，LaTeX 报告中的图片不应只是“贴上去”。将结果导出为 PDF 矢量图、设置图题和标签，并在正文中引用，能够让实验结论和证据建立清晰对应关系。后续实验中我会继续保持“先复现、再分析、后提交”的工作习惯。

## A 最终 Git 历史

下面的记录由最终本地仓库直接生成，保留了第一次程序提交、第二次报告提交以及远程 README 更新后的同步结果。

```
1 $ git log --oneline --graph --decorate -n 5
2 * b79d30c (HEAD -> main, origin/main, origin/HEAD) package completed experiment
   report
3 * 293077d update README from remote
4 * 4c692ac add experiment result and report
5 * ab6c0d2 add first experiment program
```

Listing 7: 最终 Git 提交历史

## B 最终工作区状态

```
1 $ git status --short
2 (clean working tree after packaging the report)
```

Listing 8: 最终 Git 状态